Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»



Отчет Лабораторная работа № 1

По курсу «Технологии машинного обучения»

«Разведочный анализ данных. Исследование и визуализация данных»

Москва 2020

Описание задания

Цель лабораторной работы - изучение различных методов визуализация данных.

Краткое описание - построение основных графиков, входящих в этап разведочного анализа данных.

Для выполнения данного задания я взял набор данных (датасет), отражающий экономические показатели для большинства стран мира.

Датасет содержит следующие колонки:

- Year год актуализации
- ISO_code международный код страны
- Countries название страны
- ECONOMIC FREEDOM показатель экономической независимости страны
- Rank позиция страны в мировом экономическом рейтинге
- И также много различных точечных экономических показателей

Текст программы

Программа разрабатывалась в IDE PyCharm. Ниже приведён полный листинг программы:

```
import numpy
import pandas
import seaborn
import matplotlib.pyplot as plt
%matplotlib inline
seaborn.set(style="ticks")

#%%

# This is our dataset from .csv file
data = pandas.read_csv('./dataset.csv', sep=",")

#%%

data.head()

#%%
```

```
total count = data.shape[0]
#%%
print('Strings number: {}'.format(total_count))
#%%
data.columns
data.dtypes
#%%
# Num of empty cells in 'data'
for col in data.columns:
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
#%%
data2 = data.dropna(axis=0, how='any')
(data.shape, data2.shape)
#%%
#Num of empty cells in 'data2'
for col in data2.columns:
    temp_null_count = data2[data2[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
#%%
data.describe()
#%%
data['countries'].unique()
#%%
fig, ax = plt.subplots(figsize=(10,10))
seaborn.scatterplot(ax=ax, x='rank', y='ECONOMIC FREEDOM', data=data2)
#%%
fig, ax = plt.subplots(figsize=(10,10))
seaborn.scatterplot(ax=ax, x='3_sound_money', y='3c_inflation', data=data2,
hue='rank')
#%%
fig, ax = plt.subplots(figsize=(10,10))
seaborn.distplot(data2[('ECONOMIC FREEDOM')])
#%%
fig, ax = plt.subplots(figsize=(10,10))
seaborn.distplot(data2[('1d_top_marg_tax_rate')])
```

```
#%%
seaborn.jointplot(x='3_sound_money', y='5_regulation', data=data2)
seaborn.jointplot(x='3_sound_money', y='5c_business_reg', data=data2)
#%%
seaborn.jointplot(x='rank', y='ECONOMIC FREEDOM', data=data2, kind="hex")
#%%
seaborn.jointplot(x='1 size government', y='ECONOMIC FREEDOM', data=data2,
kind="kde")
#%%
seaborn.pairplot(data2)
#%%
seaborn.pairplot(data2, vars=['ECONOMIC
FREEDOM', '1_size_government', '2a_judicial_independence', '2d_military_interference'
,'2_property_rights','3c_inflation','3_sound_money','5_regulation'])
#%%
seaborn.pairplot(data2, vars=['ECONOMIC
FREEDOM', '1_size_government', '2a_judicial_independence', '2d_military_interference'
,'2_property_rights','3c_inflation','3_sound_money','5_regulation'], hue="rank")
#%%
seaborn.boxplot(x=data['2_property_rights'])
#%%
# Vertical scrolling
seaborn.boxplot(y=data['2_property_rights'])
#%%
seaborn.violinplot(x=data2['3_sound_money'])
#%%
fig, ax = plt.subplots(2, 1, figsize=(10,10))
seaborn.violinplot(ax=ax[0], x=data2['3c_inflation'])
seaborn.distplot(data2['3c_inflation'], ax=ax[1])
#%%
seaborn.violinplot(x='year', y='3c_inflation', data=data2)
#%%
data2.corr()
```

```
#%%
seaborn.heatmap(data2.corr())
d2 = data2[['year', 'ECONOMIC
FREEDOM', '1_size_government', '2a_judicial_independence', '2j_gender_adjustment',
'2_property_rights','3c_inflation','3_sound_money','4_trade','5_regulation']]
seaborn.heatmap(d2.corr())
#%%
seaborn.heatmap(d2.corr(), cmap='YlGnBu', annot=True, fmt='.3f')
#%%
# Triangle matrix
mask = numpy.zeros_like(d2.corr(), dtype=numpy.bool)
# mask[np.triu_indices_from(mask)] = True
mask[numpy.tril_indices_from(mask)] = True
seaborn.heatmap(d2.corr(), mask=mask, annot=True, fmt='.3f')
#%%
fig, ax = plt.subplots(1, 3, sharex='col', sharey='row', figsize=(15,5))
seaborn.heatmap(d2.corr(method='pearson'), ax=ax[0], annot=True, fmt='.2f')
seaborn.heatmap(d2.corr(method='kendall'), ax=ax[1], annot=True, fmt='.2f')
seaborn.heatmap(d2.corr(method='spearman'), ax=ax[2], annot=True, fmt='.2f')
fig.suptitle('Correlation matrix by some methods:')
ax[0].title.set_text('Pearson')
ax[1].title.set_text('Kendall')
ax[2].title.set_text('Spearman')
```

Примеры выполнения программы

Выполнение программы, а также наглядная демонстрация входных и выходных данных (таблиц, графиков и тд) осуществлялась на базе Jupyter Notebook, сервер которого запускался из-под PyCharm. Ниже приведены скриншоты, отражающие работу программы:















