Московский государственный технический университет им. Н.Э. Баумана Факультет «Информатика и системы управления» Кафедра «Системы обработки информации и управления»



Отчет Лабораторная работа№ 2

По курсу «Технологии машинного обучения»

«Изучение библиотек обработки данных»

«изучение ополнотек обработки данных»	
исполнитель:	
Сергеев И.В.	
Группа ИУ5-64Б	
""2020 г.	
ПРЕПОДАВАТЕЛЬ:	
Гапанюк Ю.Е.	
-	
""2020 г.	

Описание задания

Москва 2020

Цель лабораторной работы - изучение библиотеки обработки данных Pandas.

Задание - Выполните первое демонстрационное задание "demo assignment" под названием "Exploratory data analysis with Pandas" со страницы курса https://mlcourse.ai/assignments

Текст программы

Программа разрабатывалась в IDE PyCharm. Ниже приведён полный листинг программы:

```
#%%
import numpy
import pandas
pandas.set_option('display.max.columns', 100)
%matplotlib inline
import matplotlib.pyplot as plt
import seaborn as sns
%matplotlib inline
import matplotlib.pyplot as plt
import seaborn as sns
#%%
# Firstly importing data from dataset 'adult.csv' from task
data = pandas.read csv('adult.csv')
data.head()
#%%
data['gender'].value_counts()
#%%
data.loc[data['gender'] == 'Female', 'age'].mean()
#%%
float((data['native-country'] == 'Germany').sum()) / data.shape[0]
#%%
ages1 = data.loc[data['income'] == '>50K', 'age']
ages2 = data.loc[data['income'] == '<=50K', 'age']</pre>
print("The average age of the rich: {0} +- {1} years, poor - {2} +- {3}
years.".format(
    round(ages1.mean()), round(ages1.std(), 1),
    round(ages2.mean()), round(ages2.std(), 1)))
#%%
data.loc[data['income'] == '>50K', 'education'].unique()
```

```
#%%
for (race, sex), sub_df in data.groupby(['race', 'gender']):
    print("Race: {0}, gender: {1}".format(race, sex))
    print(sub df['age'].describe())
#%%
data.loc[(data['gender'] == 'Male') &
     (data['marital-status'].isin(['Never-married',
                                    'Separated',
                                    'Divorced',
                                    'Widowed'])), 'income'].value_counts()
#%%
data.loc[(data['gender'] == 'Male') &
     (data['marital-status'].str.startswith('Married')), 'income'].value_counts()
#%%
data['marital-status'].value_counts()
#%%
max_load = data['hours-per-week'].max()
print("Max working time per week: {0}".format(max load))
num workaholics = data[data['hours-per-week']==max load].shape[0]
print("Number of workers satisfying it: {0}".format(num_workaholics))
rich_share = float(data['data['hours-per-week']==max_load)& (data['income'] ==
'>50K')].shape[0])/num_workaholics
print("Rich workers percent: {0}%".format(int(100 * rich_share)))
#%%
pandas.crosstab(data['native-country'], data['income'],
           values=data['hours-per-week'], aggfunc=numpy.mean).T
#%%
dataframe1 = {
    'UserID': [0,1,2,3,4,5,6,7,8,9],
'UserName':['Petya','Vasya','Kolya','Semen','Masha','Nikita','Dmitriy','Vasiliy','Joh
    'age':[10,12,15,22,23,60,11,34,21,10],
    'socialID':[0,1,2,3,2,1,0,3,3,1]
dataframe2 = {
    'socialID':[0,1,2,3],
    'socialNet':['Facebook','Inst','Telegram','WhatsApp']
Users = pandas.DataFrame(dataframe1,columns = ['UserID','UserName','age','socialID'])
Soc = pandas.DataFrame(dataframe2,columns = ['socialID','socialNet'])
#%%
import time
time1 = time.time()
result = pandas.merge(Users,
                 Soc,
                 on='socialID',
```

```
how='right')
time2 = time.time()
time rez=time2-time1
print("Result : \n {0}".format(result))
print("Time : {0}".format(time_rez))
#%%
import pandasql as ps
simple_query = '''SELECT * FROM Users as d1 JOIN Soc as d2 ON
d1.socialID=d2.socialID'''
time1 = time.time()
ps.sqldf(simple_query, locals())
time2 = time.time()
time rez=time2-time1
print("Bpems : {0}".format(time_rez))
data2 = pandas.read_csv('adult.csv')
data.head()
#%%
data_fires = pandas.read_csv('forestfires.csv', sep = ',')
data_fires.head()
#%%
time1 = time.time()
aggregations = {
    'area':{
        'min_area': 'min',
        'max area': 'max'
    'rain':{
        'min_rain': 'min',
        'max_rain': 'max'
    },
    'temp':{
        'min_temp': 'min',
        'max_temp': 'max',
        'average_temp': 'mean'
    },
    'wind':{
        'min_wind_speed': 'min',
        'max_wind_speed': 'max',
        'average_wind_speed': 'mean'
    },
    'day':{
        'sumarry_days': 'count'
    }
}
result = data fires.groupby('month').agg(aggregations)
time2 = time.time()
time rez=time2-time1
print("Результат : \n {0}".format(result))
print("Bpems : {0}".format(time_rez))
```

```
time1 = time.time()
# Запрос с агрегацией в PandaSQL
SQLQuerly1='''
    SELECT
        month,
        min(area) as min_area,
        max(area) as max_area,
        min(rain) as min_rain,
        max(rain) as max_rain,
        min(temp) as min_temp,
        max(temp) as max_temp,
        avg(temp) as average_temp,
        min(wind) as min_wind_speed,
        max(wind) as max_wind_speed,
        avg(wind) as average wind speed,
        count(day) as summary days
    FROM data fires
    GROUP BY month
    ORDER BY month
result = ps.sqldf(SQLQuerly1, locals())
time2 = time.time()
time_rez=time2-time1
print("Результат : \n {0}".format(result))
print("Bpems : {0}".format(time_rez))
```

Примеры выполнения программы

Выполнение программы, а также наглядная демонстрация входных и выходных данных (таблиц, графиков и тд) осуществлялась на базе Jupyter Notebook, сервер которого запускался из-под PyCharm. Ниже приведены скриншоты, отражающие работу программы:















